

UNIVERSIDAD DE CARABOBO
Facultad Experimental de Ciencia y Tecnología
Departamento de Computación

Electiva: Aprendizaje Automático

Clase 5: Clasificación con Regresión Logística

Profesor: Álvaro Espinoza

2026

Índice

1. Introducción	2
2. Objetivos de aprendizaje	2
3. Tipos de problemas de clasificación	3
3.1. Clasificación binaria	3
3.2. Clasificación multiclase	3
3.3. Clasificación multietiqueta	4
4. ¿Por qué no usar directamente regresión lineal?	4
5. La función sigmoide	4
6. La hipótesis de la regresión logística	5
6.1. Ejemplo	6
7. Probabilidad, umbral y clase predicha	6
8. La frontera de decisión	7
8.1. Fronteras no lineales mediante nuevas características	8

9. La función de costo	8
9.1. Costo cuando $y = 1$	8
9.2. Costo cuando $y = 0$	8
9.3. Binary Cross-Entropy	9
9.4. Ejemplo de interpretación	9
10. Entrenamiento mediante Gradient Descent	9
11. Regularización	10
11.1. ¿Por qué regularizar?	10
11.2. Regularización L2	11
11.3. Regularización L1	11
11.4. L1 frente a L2	11
12. Clasificación multiclase	12
12.1. One-vs-Rest	12
12.2. Softmax	12
12.3. Ejemplo	13
13. Pipeline conceptual de clasificación	13
14. Implementación con Scikit-Learn	14
14.1. Clasificación binaria	14
14.2. Clasificación multiclase	14
15. Aplicación a los proyectos de la asignatura	15
16. Limitaciones de la regresión logística	15
17. Conexión con redes neuronales	16
18. Resumen conceptual	16
19. Preguntas de reflexión	17
20. Referencias	17

1. Introducción

En la clase anterior estudiamos la regresión lineal y aprendimos a construir un modelo capaz de predecir una cantidad numérica. Ese tipo de problema aparece cuando queremos estimar el precio de una vivienda, la demanda de un producto o la temperatura de una máquina.

Sin embargo, muchos problemas reales no consisten en predecir un número, sino en decidir entre categorías. Podemos preguntarnos si una transacción es fraudulenta, si un mensaje es spam, si un cliente abandonará un servicio o si un jugador ganará una partida.

La regresión logística es uno de los modelos fundamentales para resolver estos problemas. Aunque su nombre incluye la palabra “regresión”, se utiliza principalmente para **clasificación**. Su objetivo no es producir directamente una clase, sino estimar la probabilidad de que una observación pertenezca a una categoría determinada.

Idea clave

La regresión logística no predice primero una clase. Predice una probabilidad. La clase aparece después, al aplicar una regla de decisión.

Esta clase servirá también como puente hacia las redes neuronales. Al finalizar, veremos que una regresión logística puede interpretarse como una neurona artificial sencilla.

2. Objetivos de aprendizaje

Al finalizar esta clase, el estudiante será capaz de:

- distinguir entre problemas de regresión y clasificación;
- identificar problemas de clasificación binaria, multiclase y multietiqueta;
- comprender la función sigmoide y su interpretación probabilística;
- explicar la diferencia entre probabilidad, umbral y clase predicha;
- interpretar una frontera de decisión;
- comprender la función de costo Binary Cross-Entropy;
- relacionar la optimización de la regresión logística con Gradient Descent;
- comprender el propósito de la regularización L1 y L2;
- describir las estrategias One-vs-Rest y Softmax para multclasificación;
- reconocer la regresión logística como un baseline para problemas de clasificación.

3. Tipos de problemas de clasificación

3.1. Clasificación binaria

En la clasificación binaria existen dos clases posibles. Generalmente se representan mediante las etiquetas

$$y \in \{0, 1\}.$$

Por convención, la clase etiquetada como 1 se denomina **clase positiva**, mientras que la clase 0 se denomina **clase negativa**.

Por ejemplo:

Problema	Clase 0	Clase 1
Detección de fraude	Transacción legítima	Transacción fraudulenta
Abandono de clientes	Permanece	Abandona
Correo electrónico	No spam	Spam
Predicción de victoria	Pierde	Gana

La clase positiva no necesariamente representa algo deseable. En detección de fraude, por ejemplo, la clase positiva es precisamente el evento que queremos detectar.

3.2. Clasificación multiclase

En clasificación multiclase existen más de dos clases y cada observación pertenece a una sola de ellas:

$$y \in \{1, 2, \dots, K\}.$$

Ejemplos:

- clasificar un jugador por nivel de habilidad;
- identificar una especie de flor;
- predecir el resultado de un partido como victoria, empate o derrota;
- clasificar una imagen entre varias categorías.

3.3. Clasificación multietiqueta

En clasificación multietiqueta, una observación puede pertenecer simultáneamente a varias clases.

Por ejemplo, una canción podría etiquetarse como:

$$\{\text{rock, alternativo, en vivo}\}.$$

Este curso se concentrará principalmente en clasificación binaria y multiclase. La clasificación multietiqueta se menciona para distinguirla de los dos casos anteriores.

Error común

Multiclase y multietiqueta no significan lo mismo. En multiclase se elige una sola clase entre varias. En multietiqueta pueden asignarse varias clases a una misma observación.

4. ¿Por qué no usar directamente regresión lineal?

Supongamos que queremos predecir si un cliente abandonará un servicio. Podemos intentar utilizar una regresión lineal:

$$h_{\theta}(x) = \theta^T x.$$

Sin embargo, este modelo puede producir cualquier número real:

$$-0.7, \quad 0.4, \quad 1.8, \quad 6.2.$$

Estos valores no pueden interpretarse directamente como probabilidades, porque una probabilidad debe encontrarse entre cero y uno:

$$0 \leq P(y = 1 \mid x) \leq 1.$$

Necesitamos entonces una función que reciba cualquier valor real y lo transforme en un valor dentro de ese intervalo.

5. La función sigmoide

La función sigmoide, también llamada función logística, se define como

$$g(z) = \frac{1}{1 + e^{-z}}.$$

Su salida siempre pertenece al intervalo

$$0 < g(z) < 1.$$

Algunos valores representativos son:

z	$g(z)$
-5	0.007
-2	0.119
0	0.500
2	0.881
5	0.993

Cuando z es muy negativo, la salida se aproxima a cero. Cuando z es muy positivo, se aproxima a uno. Si $z = 0$, la salida es exactamente 0.5.

Idea clave

La sigmoide no clasifica por sí sola. Su función es transformar una combinación lineal en un valor interpretable como probabilidad.

6. La hipótesis de la regresión logística

La regresión logística conserva la combinación lineal utilizada en regresión lineal:

$$z = \theta^T x.$$

Luego aplica la función sigmoide:

$$h_{\theta}(x) = g(\theta^T x).$$

Por tanto,

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}.$$

La salida del modelo puede interpretarse como

$$h_{\theta}(x) = P(y = 1 \mid x; \theta).$$

En palabras:

El modelo estima la probabilidad de que la observación pertenezca a la clase positiva, dadas sus características.

Como solo existen dos clases,

$$P(y = 0 \mid x; \theta) = 1 - h_{\theta}(x).$$

6.1. Ejemplo

Supongamos que un modelo predice

$$h_{\theta}(x) = 0.83.$$

Esto significa que el modelo estima una probabilidad de 83 % para la clase positiva. Todavía no hemos tomado una decisión de clase; únicamente disponemos de una probabilidad.

7. Probabilidad, umbral y clase predicha

Para transformar una probabilidad en una clase se utiliza un **umbral de decisión**.

Con el umbral convencional de 0.5:

$$\hat{y} = \begin{cases} 1, & \text{si } h_{\theta}(x) \geq 0.5, \\ 0, & \text{si } h_{\theta}(x) < 0.5. \end{cases}$$

Por ejemplo:

$$h_{\theta}(x) = 0.83 \implies \hat{y} = 1.$$

Pero el umbral no tiene que ser siempre 0.5. Puede cambiarse según el costo de cometer ciertos errores.

En detección de fraude, podríamos preferir un umbral más bajo para detectar más casos sospechosos. En cambio, si una falsa alarma es muy costosa, podríamos exigir una probabilidad mayor antes de asignar la clase positiva.

Pregunta para pensar

¿Qué sería más grave en un sistema médico: no detectar a un paciente enfermo o clasificar como enfermo a alguien sano? La respuesta influye directamente en el umbral.

Error común

Una probabilidad de 0.51 y una de 0.99 pueden producir la misma clase, pero no representan el mismo nivel de confianza del modelo.

8. La frontera de decisión

La frontera de decisión separa las regiones del espacio de características que el modelo asigna a clases diferentes.

Con un umbral de 0.5:

$$h_{\theta}(x) \geq 0.5$$

ocurre cuando

$$\theta^T x \geq 0.$$

Por tanto, la frontera se obtiene mediante

$$\theta^T x = 0.$$

Con dos características:

$$\theta_0 + \theta_1 x_1 + \theta_2 x_2 = 0.$$

Esta expresión representa una recta. En tres dimensiones representa un plano y en dimensiones superiores, un hiperplano.

8.1. Fronteras no lineales mediante nuevas características

La regresión logística es lineal con respecto a las características que recibe. Sin embargo, podemos incluir transformaciones polinomiales:

$$x_1^2, \quad x_2^2, \quad x_1x_2.$$

Entonces el modelo podría ser

$$h_{\theta}(x) = g\left(\theta_0 + \theta_1x_1 + \theta_2x_2 + \theta_3x_1^2 + \theta_4x_2^2\right).$$

La frontera resultante puede ser curva.

Conexión

La regresión polinomial estudiada en la clase anterior reaparece aquí como ingeniería de características para construir fronteras de decisión no lineales.

9. La función de costo

En regresión lineal utilizamos el error cuadrático medio. Para regresión logística necesitamos una función de costo compatible con probabilidades.

9.1. Costo cuando $y = 1$

Si la observación pertenece a la clase positiva, queremos que $h_{\theta}(x)$ sea cercano a uno:

$$\text{Cost}(h_{\theta}(x), 1) = -\log(h_{\theta}(x)).$$

Si el modelo asigna una probabilidad cercana a cero a una observación positiva, la penalización será muy grande.

9.2. Costo cuando $y = 0$

Si la observación pertenece a la clase negativa, queremos que $h_{\theta}(x)$ sea cercano a cero:

$$\text{Cost}(h_{\theta}(x), 0) = -\log(1 - h_{\theta}(x)).$$

9.3. Binary Cross-Entropy

Las dos expresiones pueden combinarse:

$$\text{Cost}(h_{\theta}(x), y) = -y \log(h_{\theta}(x)) - (1 - y) \log(1 - h_{\theta}(x)).$$

Para m observaciones:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})) \right].$$

Esta función también recibe los nombres:

- Binary Cross-Entropy;
- Log Loss;
- pérdida logarítmica.

Idea clave

La Binary Cross-Entropy penaliza especialmente las predicciones incorrectas realizadas con mucha confianza.

9.4. Ejemplo de interpretación

Para una observación cuya clase real es $y = 1$:

Probabilidad predicha	Interpretación	Costo aproximado
0.99	Correcta y muy segura	0.010
0.80	Correcta	0.223
0.50	Incierta	0.693
0.10	Incorrecta	2.303
0.01	Incorrecta y muy segura	4.605

10. Entrenamiento mediante Gradient Descent

El objetivo sigue siendo encontrar los parámetros que minimizan la función de costo:

$$\min_{\theta} J(\theta).$$

La regla general de actualización es

$$\theta_j := \theta_j - \alpha \frac{\partial J(\theta)}{\partial \theta_j}.$$

Para la regresión logística, el gradiente puede escribirse como

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right) x_j^{(i)}.$$

La forma se parece mucho a la utilizada en regresión lineal. La diferencia principal está en la hipótesis y en la función de costo.

Conexión

La lógica del entrenamiento no cambia: predecir, medir el error, calcular gradientes y actualizar parámetros.

El proceso puede resumirse así:

Parámetros iniciales $\rightarrow$ Probabilidades $\rightarrow$ Costo $\rightarrow$ Gradientes $\rightarrow$ Actualización.

11. Regularización

11.1. ¿Por qué regularizar?

Un modelo puede ajustar muy bien los datos de entrenamiento y, aun así, generalizar mal. Esto ocurre cuando aprende patrones demasiado específicos, ruido o relaciones accidentales.

En regresión logística, este problema puede aparecer cuando:

- existen muchas características;
- se agregan términos polinomiales;
- algunas variables son muy correlacionadas;
- el conjunto de datos es pequeño;
- el modelo encuentra una frontera excesivamente compleja.

La regularización agrega una penalización a la función de costo para evitar parámetros excesivamente grandes.

11.2. Regularización L2

La regularización L2 agrega:

$$\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2.$$

La función regularizada queda:

$$J_{L2}(\theta) = J_{\text{logística}}(\theta) + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2.$$

Generalmente no se regulariza el intercepto θ_0 .

El parámetro λ controla la intensidad de la penalización:

Valor de λ	Comportamiento esperado
Muy pequeño	El modelo conserva gran flexibilidad y puede sobreajustarse.
Adecuado	Se alcanza un equilibrio entre ajuste y generalización.
Muy grande	Los parámetros se reducen demasiado y puede aparecer underfitting.

11.3. Regularización L1

La regularización L1 agrega una penalización basada en valores absolutos:

$$\frac{\lambda}{m} \sum_{j=1}^n |\theta_j|.$$

Una característica importante de L1 es que puede llevar algunos coeficientes exactamente a cero. Por esa razón puede producir modelos dispersos y actuar como una forma de selección de variables.

11.4. L1 frente a L2

Regularización	Efecto principal	Uso frecuente
L1	Puede anular coeficientes	Modelos dispersos y selección de variables
L2	Reduce los coeficientes sin anularlos necesariamente	Control general del sobreajuste

Error común

Regularizar no significa mejorar siempre el modelo. Una penalización excesiva puede simplificarlo demasiado.

12. Clasificación multiclase

La regresión logística binaria produce una probabilidad para una clase positiva. Cuando existen K clases, necesitamos extender el procedimiento.

12.1. One-vs-Rest

La estrategia One-vs-Rest entrena un clasificador binario por cada clase.

Para la clase k , el modelo aprende a distinguir:

clase k vs. todas las demás.

Si existen tres clases, se entrenan tres modelos:

- clase 1 contra clases 2 y 3;
- clase 2 contra clases 1 y 3;
- clase 3 contra clases 1 y 2.

En predicción, se selecciona la clase con el puntaje o probabilidad más alto.

12.2. Softmax

Otra alternativa es la regresión logística multinomial con función Softmax.

Para cada clase k , el modelo calcula un puntaje:

$$z_k = \theta_k^T x.$$

Softmax transforma estos puntajes en probabilidades:

$$P(y = k \mid x) = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}.$$

Las probabilidades resultantes cumplen:

$$\sum_{k=1}^K P(y = k \mid x) = 1.$$

La clase predicha es

$$\hat{y} = \arg \max_k P(y = k \mid x).$$

Idea clave

La sigmoide es natural para clasificación binaria. Softmax es su extensión más común cuando las clases son mutuamente excluyentes.

12.3. Ejemplo

Supongamos que un modelo produce:

$$P(y = 1 \mid x) = 0.15,$$

$$P(y = 2 \mid x) = 0.70,$$

$$P(y = 3 \mid x) = 0.15.$$

La clase predicha será

$$\hat{y} = 2.$$

13. Pipeline conceptual de clasificación

Una vez comprendidos los elementos del modelo, podemos observar el flujo completo de un problema de clasificación:

Datos → Separación de conjuntos → Entrenamiento
 → Probabilidades → Umbral o regla de decisión
 → Clases predichas → Evaluación.

Por ahora asumiremos que contamos con datos de entrenamiento y prueba. La construcción correcta de estos conjuntos, la validación cruzada y las métricas se estudiarán formalmente en la Clase 7.

Error común

Separar los datos no es simplemente dividir filas al azar en todos los casos. Series temporales, grupos y clases desbalanceadas requieren estrategias específicas.

14. Implementación con Scikit-Learn

14.1. Clasificación binaria

```
1 from sklearn.linear_model import LogisticRegression
2
3 model = LogisticRegression(
4     penalty="l2",
5     C=1.0,
6     max_iter=1000
7 )
8
9 model.fit(X_train, y_train)
10
11 probabilities = model.predict_proba(X_test)
12 predictions = model.predict(X_test)
```

El método `predict_proba` devuelve las probabilidades para cada clase. El método `predict` devuelve las clases finales.

En Scikit-Learn, el parámetro `C` controla la regularización de forma inversa:

$$C = \frac{1}{\lambda} \text{ de manera conceptual.}$$

Por tanto:

- un C grande implica menor regularización;
- un C pequeño implica mayor regularización.

14.2. Clasificación multiclase

```
1 from sklearn.linear_model import LogisticRegression
2
```

```

3 model = LogisticRegression(
4     penalty="l2",
5     C=1.0,
6     max_iter=1000
7 )
8
9 model.fit(X_train, y_train)
10
11 class_probabilities = model.predict_proba(X_test)
12 class_predictions = model.predict(X_test)

```

La biblioteca selecciona una estrategia multiclase compatible con el solver y la configuración empleada.

15. Aplicación a los proyectos de la asignatura

La regresión logística debe considerarse un **baseline** importante. Antes de utilizar modelos más complejos, conviene establecer un modelo sencillo, interpretable y rápido de entrenar.

Ejemplos de uso:

- **Minecraft**: predecir si un intento de compostaje será exitoso.
- **Super Smash Bros.**: predecir el ganador de una partida.
- **Fútbol**: predecir victoria, empate o derrota mediante una extensión multiclase.
- **StarCraft II**: predecir la liga o nivel del jugador.
- **Warhammer 40k**: clasificar la facción a partir de variables de desempeño, siempre que no exista leakage.

En todos estos casos, el modelo puede servir como punto de comparación frente a árboles, ensambles o redes neuronales.

16. Limitaciones de la regresión logística

La regresión logística es útil, pero no resuelve todos los problemas.

Entre sus limitaciones se encuentran:

- modela fronteras lineales salvo que se construyan nuevas características;
- puede requerir escalamiento para algunos procesos de optimización;

- puede ser sensible a características altamente correlacionadas;
- depende de una buena representación de los datos;
- puede tener dificultades cuando la relación entre variables y clases es altamente compleja;
- no resuelve por sí sola el desbalanceo de clases;
- una buena probabilidad no garantiza una buena decisión si el umbral se elige incorrectamente.

17. Conexión con redes neuronales

La regresión logística puede interpretarse como una sola neurona artificial.

La neurona realiza tres pasos:

Entradas $\rightarrow$ Combinación lineal $\rightarrow$ Función de activación $\rightarrow$ Salida.

En forma matemática:

$$x \rightarrow z = \theta^T x \rightarrow g(z) \rightarrow \hat{p}.$$

La salida $\hat{p}$ representa una probabilidad.

Conexión

Una red neuronal puede entenderse como muchas unidades de este tipo conectadas entre sí. Cada capa aprende representaciones que sirven como entrada para la capa siguiente.

La próxima clase comenzará con la pregunta:

¿Qué ocurre si una sola neurona no es suficiente para representar la relación entre las características y la clase?

18. Resumen conceptual

La regresión logística puede resumirse mediante la siguiente secuencia:

Características $\rightarrow \theta^T x \rightarrow$ Sigmoide $\rightarrow$ Probabilidad $\rightarrow$ Umbral $\rightarrow$ Clase.

Durante el entrenamiento:

Probabilidad $\rightarrow$ Binary Cross-Entropy $\rightarrow$ Gradientes $\rightarrow$ Actualización de parámetros.

Para controlar el sobreajuste:

Función de costo + Regularización.

Para múltiples clases:

One-vs-Rest o Softmax.

19. Preguntas de reflexión

1. ¿Por qué una salida de regresión lineal no puede interpretarse siempre como probabilidad?
2. ¿Qué representa $h_{\theta}(x)$ en regresión logística?
3. ¿Cuál es la diferencia entre probabilidad predicha y clase predicha?
4. ¿Por qué el umbral de 0.5 no es universal?
5. ¿Qué representa la frontera de decisión?
6. ¿Cómo pueden las variables polinomiales producir fronteras curvas?
7. ¿Por qué Binary Cross-Entropy penaliza con fuerza una predicción incorrecta y segura?
8. ¿Qué efecto tiene aumentar λ en la regularización L2?
9. ¿Cuál es la principal diferencia entre regularización L1 y L2?
10. ¿Cómo funciona la estrategia One-vs-Rest?
11. ¿Por qué las probabilidades de Softmax suman uno?
12. ¿En qué sentido una regresión logística se parece a una neurona?

20. Referencias

- Bishop, C. M. *Pattern Recognition and Machine Learning*. Springer.
- Géron, A. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly.

- Murphy, K. P. *Probabilistic Machine Learning: An Introduction*. MIT Press.
- Ng, A. *Machine Learning Specialization*. DeepLearning.AI.
- Ng, A. *Machine Learning Yearning*.